1 Fashion Retrieval via Graph Reasoning Networks on a Similarity Pyramid

Авторы предлагают GRNet – модель для определения похожести элементов одежды, которая используется несколько представления каждой картинки в разном масштабе, в отличие от более ранних моделей, использовавших единственное векторное представление. Модель вычисляет скор близости между соответствующими представлениями, а потом осуществляет message passing по полному графу, вершинами которого являются вычисленные скоры. Таким образом предлагается вычислять итоговую близость объектов и использовать ее для рекомендательной системы.

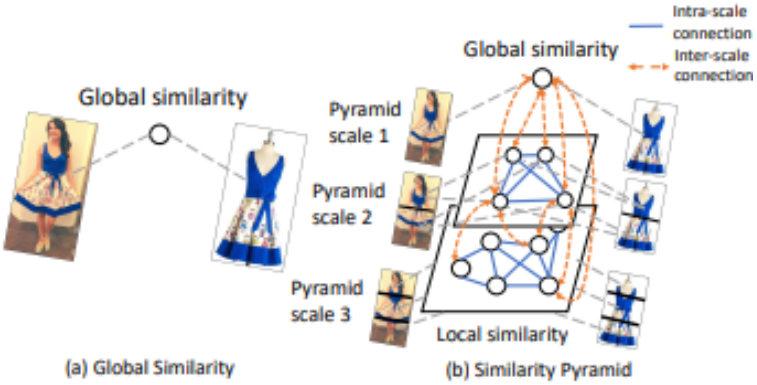

Математика:
$\{x_l^i \in \mathbb{R}^{C\times 1}\}$ и $\{y_l^i \in \mathbb{R}^{C\times 1}\}$ векторные представления i-го локального признака в l масштабе. Для каждого масштаба l и номеров признаков i и j считается вектор локальной близости s_l^{ij}:

$$s_l^{ij} = \frac{P|x_l^i - y_l^j|^2}{\|P|x_l^i - y_l^j|^2\|_2}$$

где P – проекционная матрица, снижающая размерность. Из этих векторов составляется итоговый граф (пирамида). Далее для каждой пары вершин $s_{l_1}^{ij}$ и $s_{l_2}^{mn}$ определяется скаляный вес $w_p^{l_1 i j l_2 m n}$:

$$w_p^{l_1 i j l_2 m n} = \frac{\exp((\mathbf{T}_{out} s_{l_1}^{ij})^\intercal (\mathbf{T}_{in} s_{l_2}^{mn}))}{\sum\limits_{l,p,q} \exp((\mathbf{T}_{out} s_{l_1}^{ij})^\intercal (\mathbf{T}_{in} s_l^{pq}))}$$

Тогда для $l_1 = l_2$ это веса внутри одного масштаба, а для $l_1 \neq l_2$ – между разными, что позволяет им "сообщаться". Таким образом мы определили граф близости $G = (\mathbb{N}, \mathbb{E})$, где $\mathbb{N} = \{s_l^{ij}\}$ а $\mathbb{E} = \{w_p^{l_1 i j l_2 m n}\}$.
Далее вектора в каждой вершине обновляются по следующему правилу:

$$\widehat{s}_{l_1}^{ij} = ReLU\left(W \sum_{l_2,m,n} w_p^{l_1 i j l_2 m n} s_{l_2}^{mn}\right)$$

2 Dressing as a Whole: Outfit Compatibility Learning Based on Node-wise Graph Neural Networks

Авторы рассматривают задачи поиска подбора подходящего недостающего элемента одежды и оценки совместимости предложенного образа, используя граф, в котором каждая вершина есть категория элемента одежды, а каждый образ есть подграф.

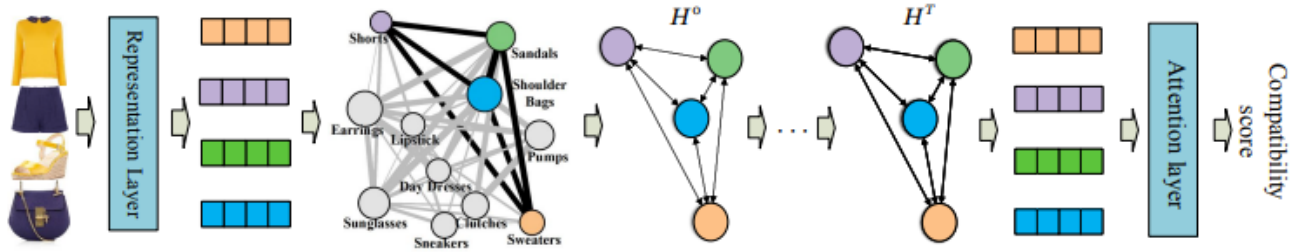

Математика:
Рассматривается множество образов $\mathcal{S} = \{s_1, s_2, \dots\}$ и множество элементов одежды $\mathcal{V} = \{v_1, v_2, \dots\}$. Для каждого элемента v_i f_i – вектор его признаков f_i а его представление в латентном пространстве r_i. Каждый v_i также принадлежит некоторой категории c_i. Вершина графа соответствующая категории c_i – n_i, ее состояние – h_i. Множество всех n_i объединяется в граф $\mathcal{G} = (\mathcal{N}, \mathcal{E})$. Веса каждого ребра определяются как:

$$w(n_i, n_j) = \frac{Count_{c_i,c_j}/Count_{c_j}}{\sum_k Count_{c_i,c_k}/Count_{c_k}}$$

где $Count_{c_i,c_j}$ – частота совместной встречаемости категорий c_i и c_j, а $Count_{c_i}$ – категории c_i.
Скрытые состояния вершин инициализируются как

$$h_i^0 = tanh(r_i) = tanh(W_h^i f_i)$$

После инициализации следует несколько шагов взаимодействия вершин. На шаге t вершина i получает функцию всех своих соседей следующего вида:

$$a_i^t = \sum_{n_j \to n_i \in \mathcal{E}} A[n_i, n_j] W_\rho h_j^{t-1} + b_\rho$$

где W_ρ и b_ρ – веса и смещение общего для всех ребер линейного преобразования, A – матрица смежности вида:

$$A[n_i, n_j] = \begin{cases} w(n_i, n_j), if\ n_i \to n_j \in \mathcal{E} \\ 0, else \end{cases}$$

Чтобы сделать взаимодействие уникальным для каждой пары вершин, но не вводить уникальные матрицы для каждого ребра, вводятся 2 матрицы для каждой вершины W_{out}^i, W_{in}^j, а матрица W_rho для каждого ребра $n_i \to n_j$ заменяется на:

$$W_\rho^{n_i \to n_j} = W_{out}^i W_{in}^j$$

Далее происходит преобразования состояния вершины n_i вида:

$$z_i^t = \sigma(W_z a_i^t + U_z h_i^{t-1} + b_z)$$

$$r_i^t = \sigma(W_r a_i^t + U_r h_i^{t-1} + b_r)$$
$$\tilde{h}_i^t = tanh(W_h a_i^t + U_h(r_i^t \odot h_i^{t-1}) + b_h)$$
$$h_i^t = \tilde{h}_i^t \odot z_i^t + h_i^{t-1}(1 - z_i^t)$$

где $W_z, W_r, W_h, b_z, b_r, b_h$ – обучаемые параметры, z_i^t и r_i^t – "gate"и "reset gate"векторы соответственно. Указанная процедура повторяется T раз.
Наконец, после T рекуррентных шагов для получения итогового скора применяется $self - attention$ над всеми вершинами графа.

3 Fashion Outfit Complementary Item Retrieval

Скукотень какая-то, придумали лосс, который почти триплет, но не триплет, и делают свертки.

4 Hierarchical Fashion Graph Network for Personalized Outfit Recommendation

Авторы статьи предлагают кроме совместимости образа рассматривать также консистентность предложений с предпочтениями пользователя. Для этого предлагается построить граф с иерархической структурой из 3-х уровней: уровень пользователя, уровень образов и уровень элементов одежды.

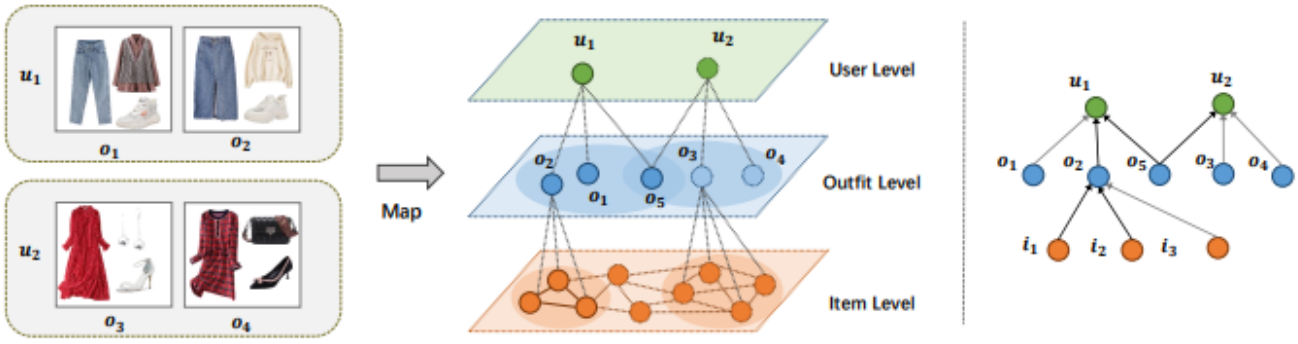

На каждом из трех уровней эмбедингги последовательно взаимно уточняются с помощью. Математика – буквально свертки с нелинейностями и усреднения

5 OutfitTransformer: Learning Outfit Representations for Fashion Recommendation

Авторы предлагают использовать архитектуру трансформера для обучения информативного представления образа целиком. Полученное представление используется для оценки совместимости образа, восстановления образа с пропущенными элементами и рекомендации подходящих вещей. Помимо изображений элементов одежды, авторы также используют их текстовое описание и одновременно тренируют 2 энкодера для текстового и графического представления каждого объекта.

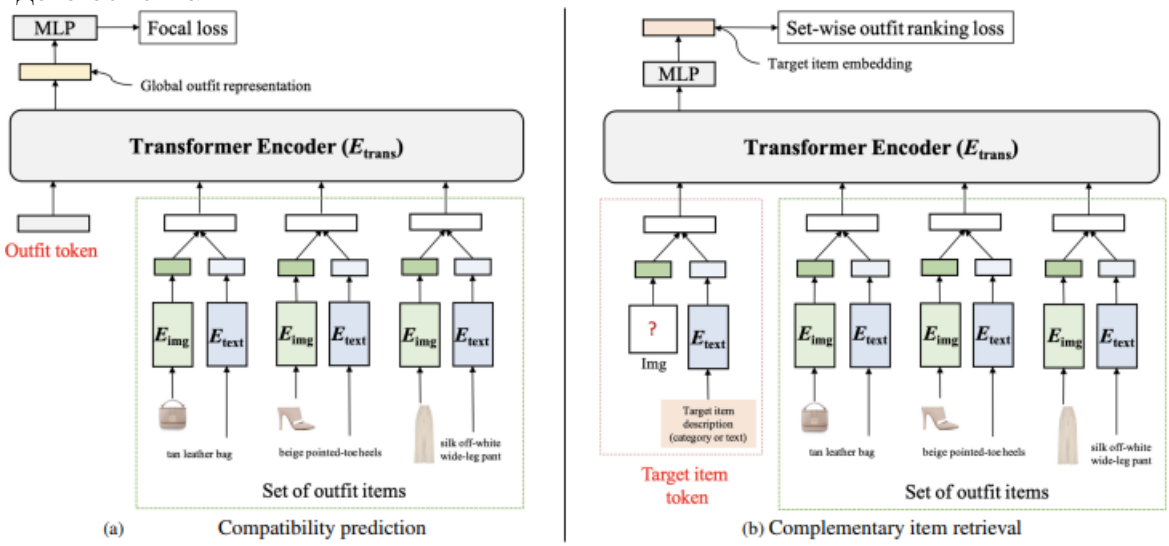

Стоит заметить, что подход к использованию трансформера в данном случае не совсем традиционный: позиционное кодирование не используется, поскольку каждый элемент в образе равноправен, а значит операции в модели должны быть инвариантны к их перестановке (так это же снова граф!).

Обучают сначала в левом сетапе (оценка совместимости), а потом дообучают под правый (подбор подходящих элементов на основании эмбединга образа). Для левого используется focal loss. Для правого "set-wise outfir ranking loss"следующего вида:

$$L(t,p,N) = L(t,p,N)_{All} + L(t,p,N)_{Hard}$$

$$L(t,p,N)_{All} = \frac{1}{|N|} = \sum_{j=1}^{|N|}[d(t,f^p) - d(t,f_j^N) + m]_+$$

$$L(t,p,N)_{Hard} = \frac{1}{|N|} = \sum_{j=1}^{|N|}[d(t,f^p) - \min_{j=1...|N|}(t,f_j^N) + m]_+$$

где t – выход линейной сети после трансформера, f^p – позитивный пример (выбран из готового образа, оставшаяся часть которого пропускается через трансформер), f^N для $L(t,p,N)_{All}$ – негативные примеры случайно насемпленные из всего датасета, для $L(t,p,N)_{Hard}$ – hard-negative-ы насемпленные из узких неподходящих к образу категорий, m – margin, $[..]_+$ – hinge-loss.

6 FAME-ViL: Multi-Tasking Vision-Language Model for Heterogeneous Fashion Tasks

Авторы изучают вопрос обучения мультимодальной модели сразу на несколько задач связанных с образами. Предложенная модель с помощью специфических адаптеров, превосходит все существовавшие подходы на каждой рассматриваемой задаче по отдельности.

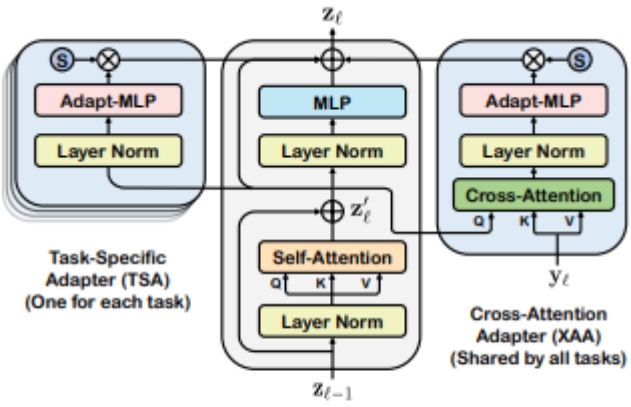

Figure 3. An illustration of a task-versatile Transformer layer equipped with two newly-introduced adapters: cross-attention adapter (XAA) and task-specific adapter (TSA).

Основой архитектуры предложенной модели выступает претренированный CLIP – мультимодальный трансформер для текстовой и визуальной информации. Для того, чтобы приспособить модель к выполнению различных задач рекомендации, распознавания и оценки образов авторы предлагают 2 вида адаптеров: TSA – Task-Specific Adapter для обучения специфическим для каждой задачи особенностям и XAA – Cross-Attention Adapter для обеспечения возможности взаимодействиями между различными модальностями, общий для всех задач. Для TSA предлагается ввести дополнительные линейные слои (AdaptMLP) после каждого self-attention блока параллельно с основными:

$$z_l^{tsa} = s \cdot AdaptMLP(LN(z_l'))$$

где s – Обучаемый множитель.

В XAA используется дополнительный Multi-Head Cross Attention (MHXA) с группой линейных слоев после него:

$$z_l^{xaa} = s \cdot AdaptMLP(LN(MHXA(z_l', y_l)))$$

где y_l выход self-attention слоя части сети для другой модальности.
Далее полученные z_l^{tsa} и z_l^{xaa} аггрегируются с обычным выходом следующим образом:

$$z_l = MLP(LN(z_l')) + z_l' + z_l^{tsa} + \epsilon \cdot z_l^{xaa},\ \epsilon \in \{0, 1\}$$

ϵ – барьерный множитель включающий или выключающий определенный адаптер для определенной задачи.

Рассматриваемая архитектура обучается на разные задачи в трех режимах Contrastive, Fusion и Generative с различными используемыми адаптерами и функциями потерь.

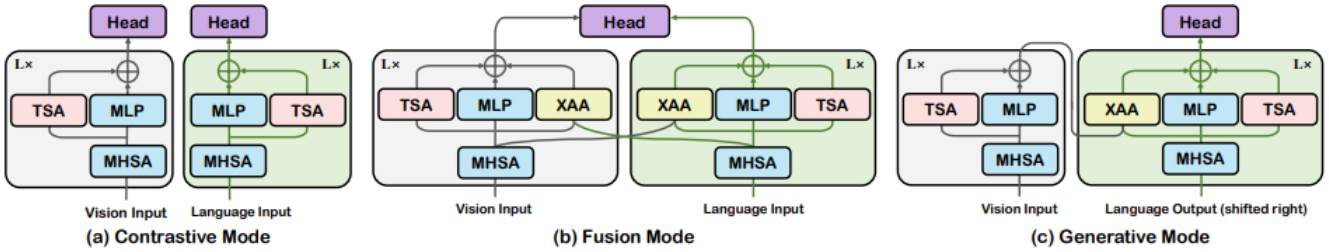

Contrastive mode:
Этот режим используется для кросс-модальных рекомендаций (XMR) (текст по картинке/картинка по тексту). Все XAA блоки отключены. Обучение производится на выборках пар картинка-текст $(\mathbf{I}, \mathbf{T}) = \{(I_1, T_1), \ldots, (I_B, T_B)\}$, сначала они по отдельности проходят через части сети для соответствующей модальности, потом с помощью контрастной функции потерь производится максимизация схожести выходов этих частей.

$$\mathcal{L}_{XMR} = \frac{1}{2}[\mathcal{L}_{InfoNCE}(\mathbf{T}, \mathbf{I}) + \mathcal{L}_{InfoNCE}(\mathbf{I}, \mathbf{T})]$$

$$\mathcal{L}_{InfoNCE} = -\frac{1}{B}\sum_{i=1}^{B} \log \frac{\exp(s(X_i, Y_i)/\tau)}{\sum_{j=1}^{B} \exp(s(X_i, Y_j)/\tau)}$$

где τ – обучаемая (???) температура. s – симметричная функция схожести $s(I_i, T_j) = f_\theta^{[c]}(I_i)^T \cdot f_\theta^{[c]}(T_j)$, где $f_\theta^{[c]}$ – собственно нейросеть.

Fusion mode:
Используется для субкатегориального распознавания (SCR) и направляемых текстом рекомендаций (TGIR). И XAA, и TSA блоки включены.
Задача SCR – предсказание подкатегории для данного товара, основываясь на тексте и картинке. Исходя из специфики задачи, к выходу сети дополнительно добавляется классификатор, cross-entropy-loss которого и минимизируется:

$$\mathcal{L}_{SCR} = -\mathbb{E}_{(I,T)\sim D} \log P\left(f_\theta^{[f]}(I, T)\right)$$

Для TGIR подход немного другой, поскольку необходимо получить представления отдельно для исходной картинки с текстовым промптом и целевой картинки, поэтому для $(\mathbf{I^r}, \mathbf{T})$ соответственно исходных картинок и текстовых запросов сеть запускается в $fusion$ режиме, а для целевых изображений I^t в *contrastive* режиме. Далее считается контрастная функция потерь вида

$$\mathcal{L}_{TGIR} = \mathcal{L}_{InfoNCE}((I^r, T), I^t)$$

Generative mode:
Используется, например, для генерации подписей к картинкам в авторегрессионном режиме. TSA блоки включены в обеих модальностях, XAA – только image-to-text. Причем часть обрабатывающая входное изображение используется как энкодер, а вторая – как декодер. Функция потерь классическая для seq2seq трансформера.

Кроме упомянутого интересно, что авторы используют идею Multi-Teacher Distillation для обучения модели на все задачи одновременно. Для начала они обучают модель такой же архитектуры на каждую задачу в отдельности, а потом дистиллируют знания всех обученных моделей в одну.